Computer Architecture

15. IO System

Jianhua Li
College of Computer and Information
Hefei University of Technology

内容概要

- 6.1 引言
- 6.2 外部存储设备
- 6.3 可靠性、可用性和可信性
- 6.4 廉价磁盘冗余阵列RAID
- 6.5 I/O设备与CPU和存储器的连接
- 6.6 I/O与操作系统

引言

- □ 输入/输出系统简称I/O系统
 - I/O设备:键盘、鼠标等
 - I/O设备与处理机的连接
- □ I/O系统的重要性
 - I/O是Von Neumann架构的重要组成部分
- □ 衡量指标:
 - 响应时间 (Response Time)
 - 可靠性 (Reliability)

I/O系统性能与CPU性能的一个谬论

- □ **谬论**:使用多进程技术可以忽略I/O性能对系统性能的影响。
 - 多进程技术只能够提高系统吞吐率,并不能够减少系统响应时间;
 - 进程切换时可能需要增加I/O操作;
 - 可切换的进程数量有限,当I/O处理较慢时,仍然 会导致CPU处于空闲状态;

性能示例

例 6.1 假设一台计算机的I/O处理占10%,当其 CPU性能按照如下方式改进,而I/O性能保持不变时,系统总体性能会出现什么变化?

- · 如果CPU的性能提高10倍
- · 如果CPU的性能提高100倍

性能示例

解:假设原来的程序执行时间为1个单位时间。如果CPU的性能提高10倍,程序的计算(包含I/O处理)时间为:

(1 - 10%)/10 + 10% = 0.19

也就是说:整机性能只能提高约5倍,差不多有**50%** 的时间浪费在I/O上。

如果CPU性能提高100倍,程序的计算时间为:

(1 - 10%)/100 + 10% = 0.109

而整机性能只能提高约10倍,表示有*90%*的时间浪费 在没有改进的I/O上了。

I/O系统的可靠性

- □ 当前处理器性能已经很高,在很多场景下人们更加关注系统可靠性。
 - 为什么可靠性这么重要?
- □ 可信性是存储系统的基础(云存储!)
 - 可靠性?
 - 可用性?
 - 可信性?

内容概要

- 6.1 引言
- 6.2 外部存储设备
- 6.3 可靠性、可用性和可信性
- 6.4 廉价磁盘冗余阵列RAID
- 6.5 I/O设备与CPU和存储器的连接
- 6.6 I/O与操作系统

外部存储设备

- □ 各种外部存储器的相似之处
 - 记录原理类似:磁性、电阻、电压等;
 - 作为计算机部件,均包括驱动机制;
 - 作为存储设备,均包括控制器及接口逻辑;
 - 均采用定位和校正技术以及相似的读写系统。
- □ 目前常用的存储设备:
 - 磁盘
 - Flash, SSD等
 - 光盘、磁带 (逐渐消退。。。)

磁盘-Hard Disk

- □ 磁盘占据着非易失性存储器的主导地位
 - 它是存储层次中主存的下一级存储层次
 - 它是虚拟存储器技术的物质基础
 - 它是操作系统和所有应用程序的驻留介质
- □ 磁盘的结构组成
 - 盘片:
 - □ 数量: 1~12 转速: 3600~15000转
 - □ 盘径: 1.0英寸(25.4厘米)~3.5英寸(8.9厘米)
 - 磁道: 每面5000~30000道
 - 扇区: 每道100~500个

磁盘结构图



图6.2 磁盘结构图 (动态)

- □ 访问时间
 - 磁盘的工作过程:
 - □ 磁头首先移动到目标磁道上
 - □ 使期望的扇区旋转到磁头下
 - □ 读取扇区中的数据
 - 工作均在磁盘控制器的控制下完成

磁盘访问时间 = 寻道时间 + 旋转时间 + 传输时间 + 控制器开销

- □ 磁盘容量
 - 磁盘容量与盘片数量和单碟容量有关。
 - 受工业标准的限制,硬盘中能安装的盘片数目有限: 3~4片。一般都是5片以内。
 - 提高单碟容量的途径有两个:
 - □ 提高道密度
 - □ 提高位密度
 - 目前的主流3.5英寸硬盘的单碟容量已经达到了百 GB。最新的可以达TB级别。

- □ 磁盘缓存 (Disk Cache)
 - 可以弥补磁盘和主存之间的速度差距
 - 利用被访问数据的局部性原理
 - □ 时间局部性
 - □ 空间局部性
 - 磁盘缓存的管理和实现一般是软硬件协同

- □ 磁盘的发展
 - 磁盘容量的提高通常用面密度来衡量
 - □ 面密度为单位面积可以记录的数据位数
 - □ 面密度 = 磁盘面的道密度×磁道的位密度
 - 容量不断提升,每位价格不断下降。
 - 磁盘的性能价格比高于主存,但访问速度却要低得多。换句话说,性能价格比与速度要求差距太大。

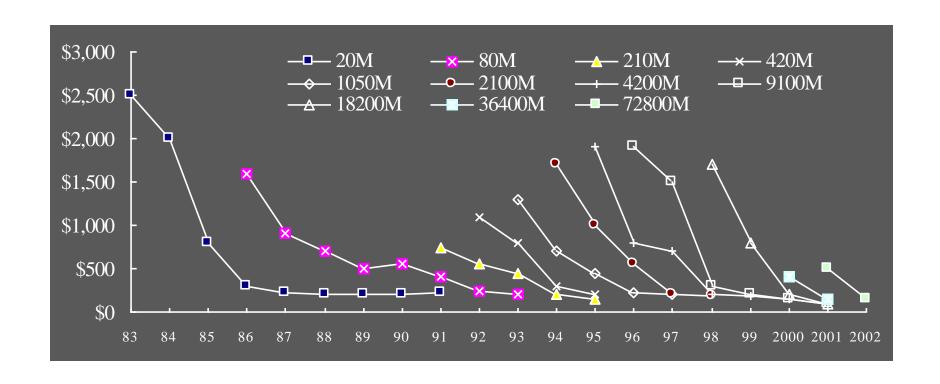


图6.3 磁盘价格的变化

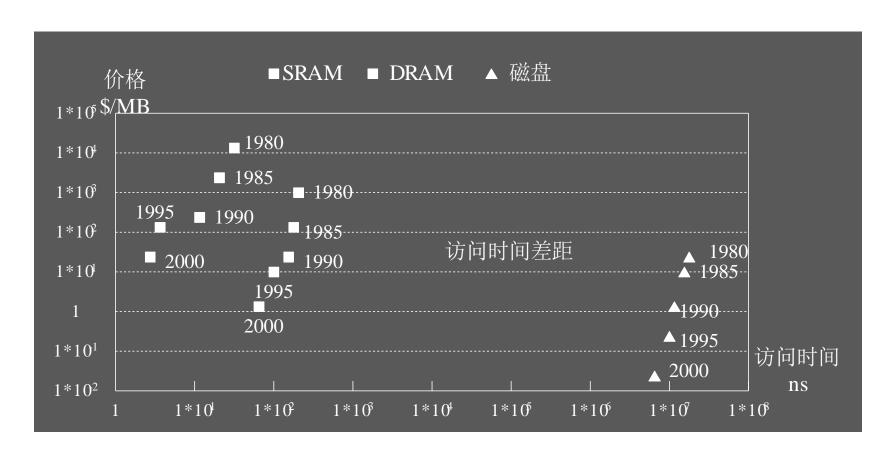


图6.4 磁盘和半导体存储器之间的访问时间差距

Flash存储器

- □ 工作原理同E2PROM,容量比E2PROM大。
- □ 与磁盘相比的主要特点:
 - 助耗小 (≤50mw)
 - 尺寸小/存储密度大
 - 提供与DRAM相仿的访问速度
 - 价格高

固态硬盘 (SSD)



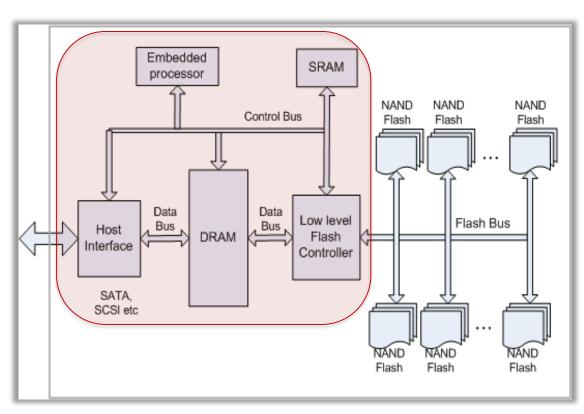


图6.5 固态硬盘的结构图和架构图

固态硬盘优点

- □ 极好的读延迟和顺序写带宽
- □ 较低的 \$/IOPS/GB
- □ 较低的功耗开销
- □ 无机械部件,更加可靠
- □ 封装尺寸更小,无noise

内容概要

- 6.1 引言
- 6.2 外部存储设备
- 6.3 可靠性、可用性和可信性
- 6.4 廉价磁盘冗余阵列RAID
- 6.5 I/O设备与CPU和存储器的连接
- 6.6 I/O与操作系统

可靠性、可用性和可信性

- □ 系统可靠性
 - 系统从初始状态开始一直提供服务的能力
 - 用平均无故障时间MTTF来衡量
- □ 系统可用性
 - **工作时间在连续两次正常服务间隔时间**中所占比率
 - 用MTTF/MTBF (平均失效间隔时间) 来衡量
- □ 系统可信性
 - 多大程度上可以合理地认为服务是可靠的
 - 可信性不可度量

可靠性、可用性和可信性示例

例 6.2 假设磁盘子系统的组成部件和它们的MTTF 如下:

- ① 磁盘子系统由10个磁盘构成,每个磁盘的MTTF为 1000000小时;
- ② 1个SCSI控制器,其MTTF为500000小时;
- ③ 1个不间断电源,其MTTF为200000小时;
- ④ 1个风扇,其MTTF为200000小时;
- ⑤ 1根SCSI连线,其MTTF为1000000小时。

可靠性、可用性和可信性示例

假定每个部件的正常工作时间服从指数分布,即部件的工作时间与故障出现的概率无关;同时假定各部件的故障相互独立,试计算整个系统的MTTF。

解:整个系统的失效率为:

系统失效率
$$=10 \times \frac{1}{1000000} + \frac{1}{5000000} + \frac{1}{2000000} + \frac{1}{2000000} + \frac{1}{10000000}$$

$$= \frac{23}{10000000}$$

可靠性、可用性和可信性示例

系统的MTTF为系统失效率的倒数,即:

MTTF =
$$\frac{1000000}{23}$$
 = 43500 小时

大约为5年

可靠性、可用性和可信性

- □ 提高系统可靠性的方法
 - 有效构建方法
 - 纠错方法
- □ 具体的说,可分为:
 - 故障避免技术
 - 故障容忍技术
 - 错误消除技术
 - 错误预报技术

内容概要

- 6.1 引言
- 6.2 外部存储设备
- 6.3 可靠性、可用性和可信性
- 6.4 廉价磁盘冗余阵列RAID
- 6.5 I/O设备与CPU和存储器的连接
- 6.6 I/O与操作系统

廉价磁盘冗余阵列RAID

- □ 廉价磁盘冗余阵列
 - Redundant Array of Inexpensive Disks
- □ 独立磁盘冗余阵列
 - Redundant Array of Independent Disks
- □ 简称盘阵列技术
 - 1988年, David Patterson的研究小组首先提出。

[PDF] A Case for Redundant Arrays of Inexpensive Disks (RAID)

https://www.cs.cmu.edu/~garth/RAIDpaper/Patterson88.pdf ▼ 翻译此页

作者: DA Patterson - 被引用次数: 4077 - 相关文章

A Case for Redundant Arrays of Inexpensive Disks (RAID). Davtd A Patterson, Garth Gibson, and Randy H Katz. Computer Saence D~v~smn. Department of ...

各级RAID的共性

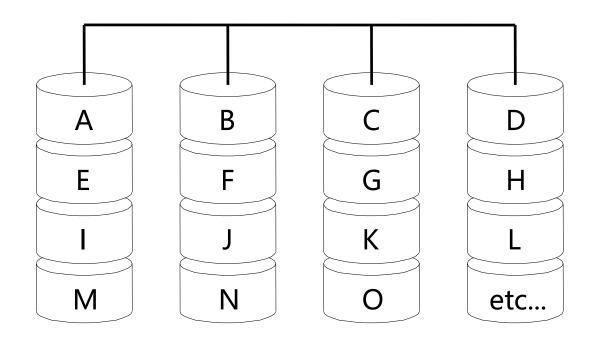
- ① RAID由一组物理磁盘驱动器组成,操作系统视 之为一个逻辑驱动器。
- ② 数据分布在一组物理磁盘上
- ③ 冗余信息被存储在冗余磁盘空间中,保证磁盘 在万一损坏时可以恢复数据。
- ④ 其中第②③个特性在不同的RAID级别中的表现不同,RAID-0不支持第3个特性。

RAID面对的问题

- □ 关键问题:如何发现磁盘的失效
 - 磁盘技术(扇区中)提供了故障检测操作的信息。
- □ 设计的另一个问题
 - 如何减少平均修复时间MTTR
 - 典型的做法: 在系统中增加热备份盘
- □ 热切换技术
 - 与热备份盘相关的一种技术
 - 不用关机就能更换设备

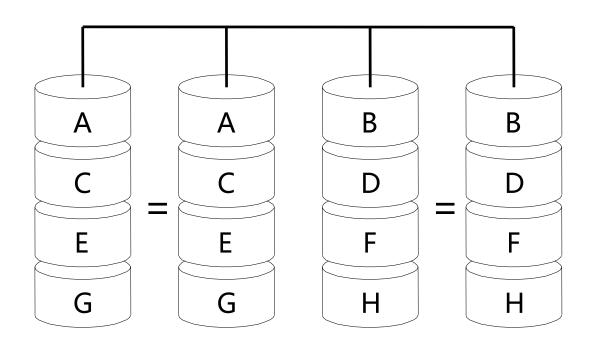
RAID-0

- □ 数据分块,即把数据分布在多个盘上。
- □ 非冗余阵列、无冗余信息。
- □ 严格地说,它不是RAID。



RAID-1

- □ 亦称镜像盘,使用双备份磁盘。
- □ 每当数据写入一个磁盘时,将该数据也写到另 一个冗余盘,形成信息的两份复制品。

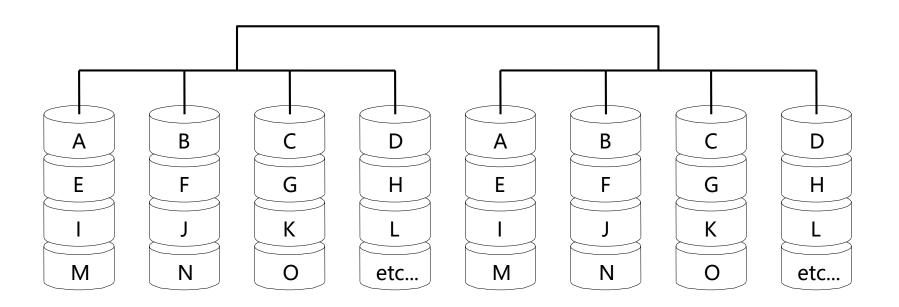


RAID-1特点

- □ 读性能好
 - RAID-1的性能能够达到RAID-0性能的两倍。
- □ 写性能由写性能最差的磁盘决定。
 - 相对后面各级RAID来说, RAID-1的写速度较快。
- □ 可靠性很高(很显然)
- □ 最昂贵的解决方法
 - 物理磁盘空间是逻辑磁盘空间的两倍。

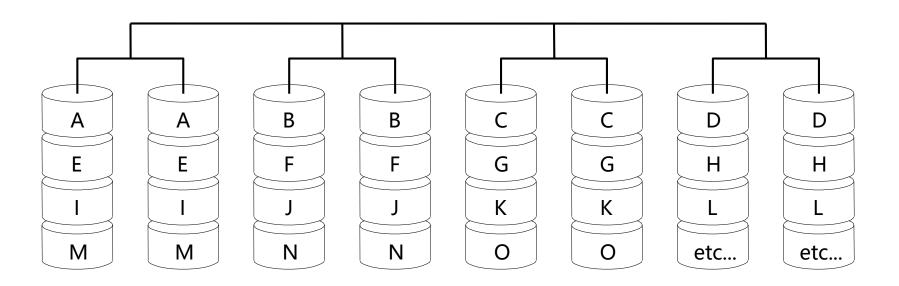
RAID-01

□ RAID-0 —> RAID-1 先分块后镜像



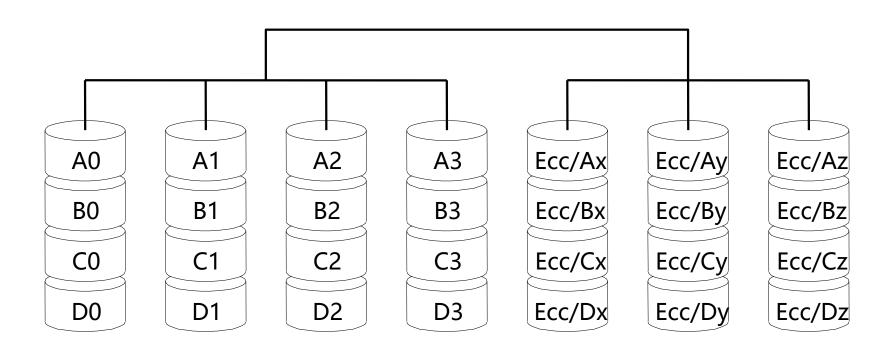
RAID-10

□ RAID-1 —> RAID-0 先镜像后分块



RAID-2 (bit-interleaved hamming code)

- □ 位交叉式海明编码阵列
- □ 各个数据盘上的相应位计算海明校验码,编码 位被存放在多个校验(ECC)磁盘的对应位上。

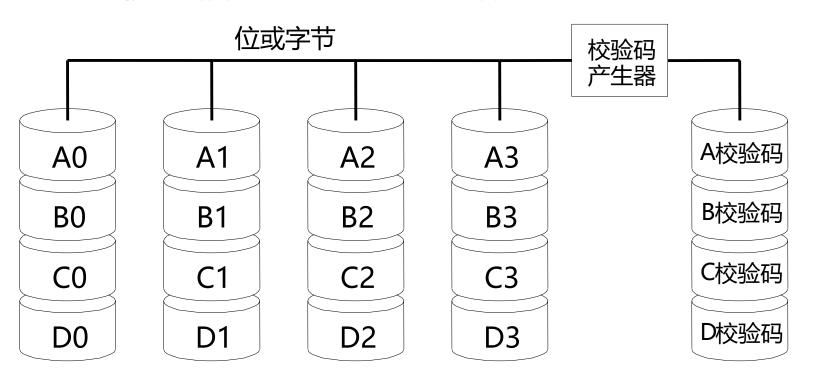


RAID-2特点

- □ 并行存取,各个驱动器同步工作。
- □ 使用海明编码来进行错误检测和纠正,数据传输率高。
- □ 需要多个磁盘来存放海明校验码信息,冗余磁盘数量与数据磁盘数量的对数成正比。
- □ 是一种在多磁盘易出错环境中的有效选择。并 未被广泛应用,目前还没有商业化产品。
 - 为什么没有商业化产品?

RAID-3 (bit/byte-interleaved parity)

- □ 位交叉奇偶校验盘阵列
- 单盘容错并行传输:数据以位或字节交叉存储, 奇偶校验信息存储在一台专用盘上。



RAID-3特点

- □ 将磁盘分组,读写要访问组中所有盘,每组中有一个盘作为校验盘。
- □ 校验盘一般采用奇偶校验。
- □ 简单理解: 先将分布在各个数据盘上的一组数据加起来,将和存放在冗余盘上。一旦某一个盘出错,只要将冗余盘上的和减去所有正确盘上的数据,得到的差就是出错的盘上的数据。
 - 优点:高数据传输率,空间开销小。
 - 缺点:恢复时间较长,不能同时支持多个IO请求。

RAID-3读写特点

假定:有4个数据盘和1个冗余盘:

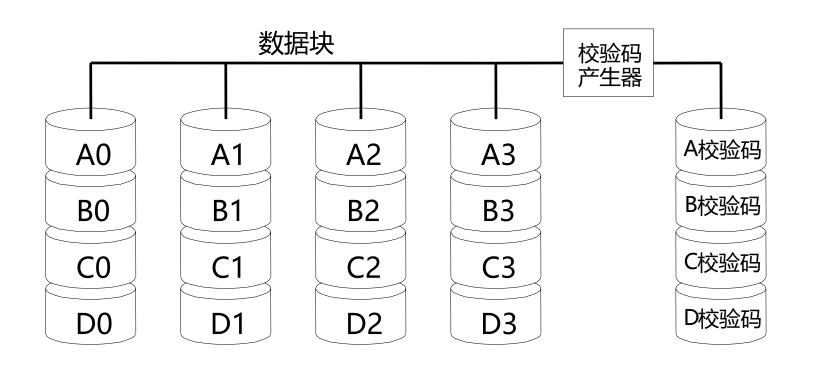
• 读出数据时通常涉及所有磁盘;

写数据需要3次磁盘读和2次磁盘写操作【如

读操作 读操作 读操作 D0 D2 **D3** D0 ' D1 P 异或 D0 ' D2 **D3** D1 写操作 写操作

RAID-4 (block-interleaved parity)

- □ 专用奇偶校验独立存取盘阵列
- □ 数据以块(块大小可变)交叉的方式存于各盘, 奇偶校验信息存在一台专用盘上。



RAID-4特点

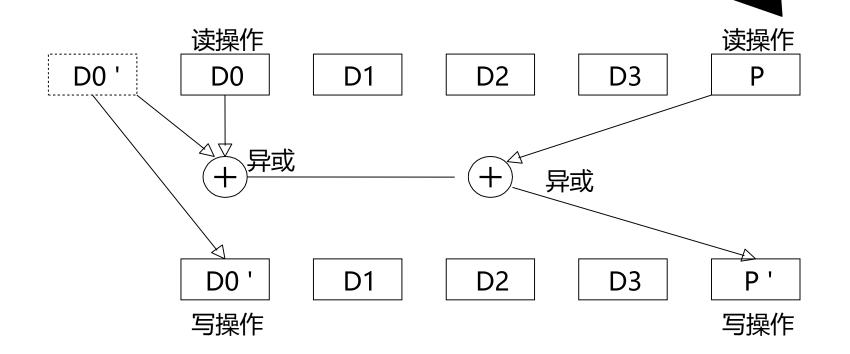
- □ 冗余代价与RAID-3相同
- □ 访问数据的方法与RAID-3不同
 - 在RAID-3中,一次磁盘访问将对磁盘阵列中的所 有磁盘进行操作。
 - RAID-4出现的原因:
 - □ 希望使用较少的磁盘参与操作,以使磁盘阵列可以并行 进行多个数据的磁盘操作。

RAID-4读写特点

假定:有4个数据盘和1个冗余盘

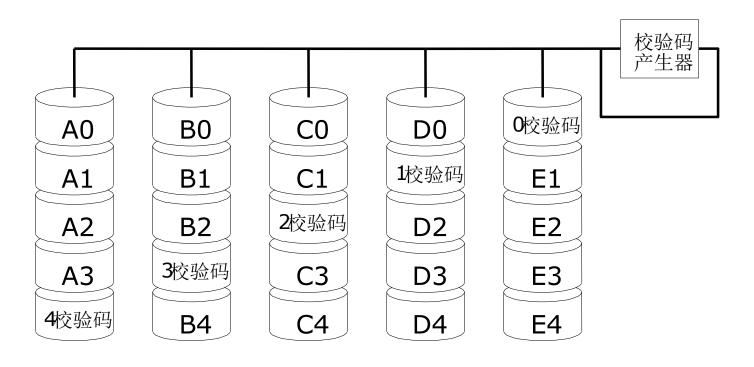
- 读出数据,仅仅需要读取数据对应的磁盘;
- 写数据需要2次磁盘读和2次磁盘写操作。

校验盘也是系 统瓶颈!!!

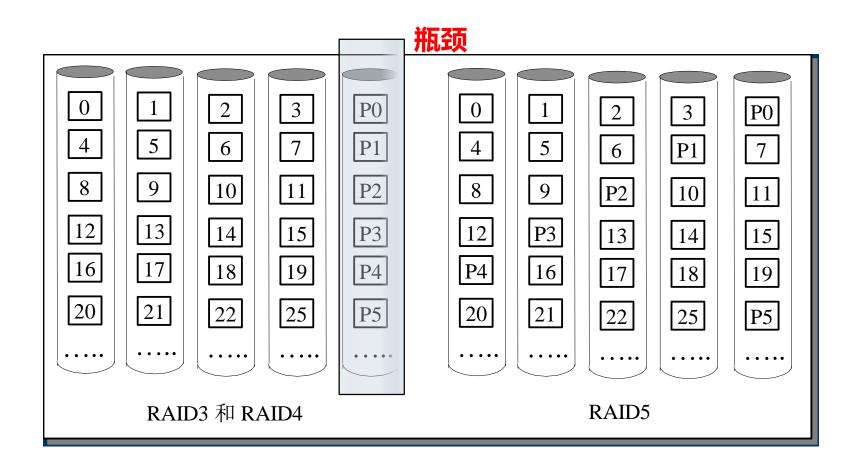


RAID-5 (block-interleaved distributed parity)

- □ 块交叉分布式奇偶校验盘阵列
- □ 数据以块交叉的方式存于各盘,无专用冗余盘, 奇偶校验信息均匀分布在所有磁盘上。

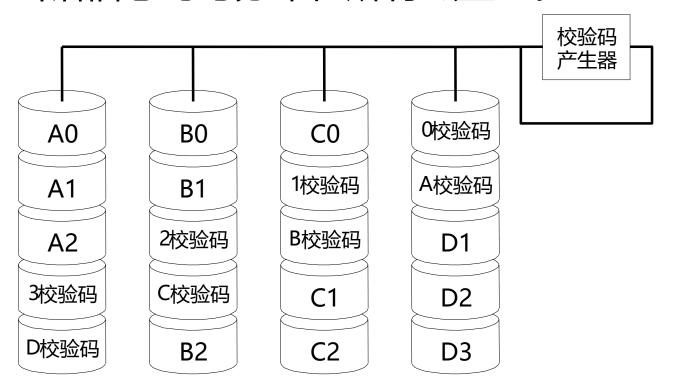


RAID-5的校验信息分布



RAID-6

- □ 双维奇偶校验(P+Q校验)独立存取盘阵列
- □ 数据以块(块大小可变)交叉方式存于各盘,检、 纠错信息均匀分布在所有磁盘上。



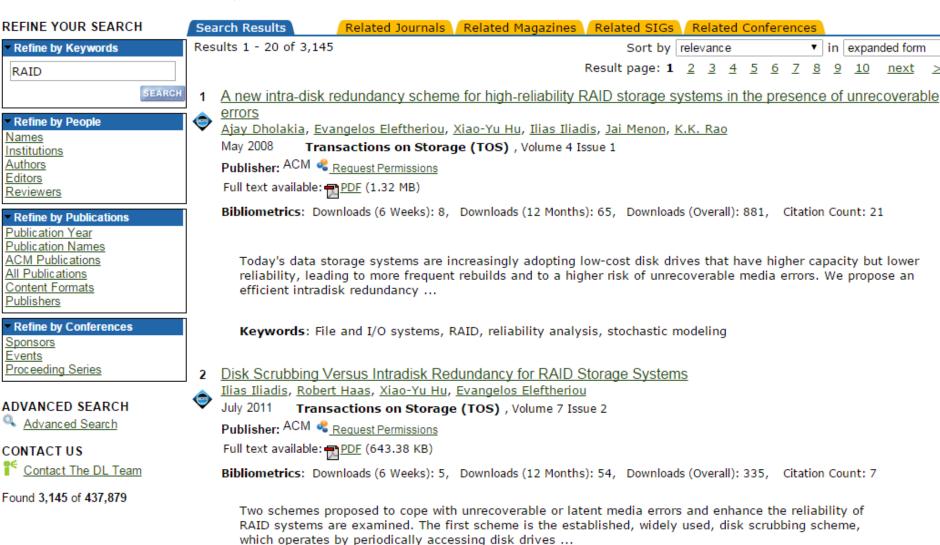
RAID-6特点

- □ 读操作与RAID-5类似;
- □ 可容忍双盘出错,适用于高可靠性要求的场景;
- □ 存储开销是RAID-5的两倍;
- □ RAID-6的写过程需要6次磁盘操作。
 - 过程是怎么样的呢?

RAID的实现与发展

- □ 实现盘阵列的方式主要有三种
 - 软件方式: 阵列管理软件由主机来实现
 - □ 优点:成本低
 - □ 缺点: 过多地占用主机时间,并且带宽指标上不去。
 - 阵列卡方式
 - □ 把RAID管理软件固化在I/O控制卡上
 - □ 从而可不占用主机时间,一般用于工作站和PC机。
 - 子系统方式
 - □ 这是一种基于通用接口总线的开放式平台,可用于各种主机平台和网络系统。

RAID的实现与发展



3 Disk scrubbing versus intra-disk redundancy for high-reliability raid storage systems

Keywords: MTTDL, RAID, Unrecoverable or latent sector errors, reliability analysis, stochastic modeling

内容概要

- 6.1 引言
- 6.2 外部存储设备
- 6.3 可靠性、可用性和可信性
- 6.4 廉价磁盘冗余阵列RAID
- 6.5 I/O设备与CPU和存储器的连接
- 6.6 I/O与操作系统

6.5 I/O设备与CPU和存储器的连接

- □ 通过接口将许多子系统连接起来
- □ 接口使用的最多的就是总线
- □ 输入输出方式:
 - 程序查询
 - ■中断
 - DMA
 - ■通道

总线 (bus)

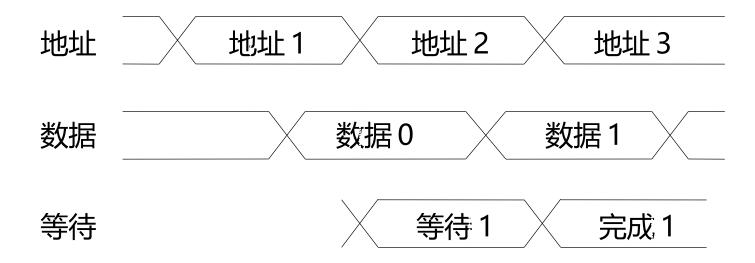
- □ 优点: 低成本、多样性
 - BitBus, MultiBus, UniBus, PC-Bus(8), AT-Bus(16), PCI, Compact PCI, PCI-E, PCI-X, VXI, PXI, SCXI, RS-232C, RS-422, RS-485, USB, 1394, SATA, PATA, SCSI, AMBA ...
- □ 缺点:必须独占使用,造成了设备信息交换的 瓶颈,从而限制了系统中总的I/O吞吐量。
 - 多核系统逐渐转到基于NoC的架构上的主要原因

总线的设计

选择	高性能	低价格
总线宽度	独立的地址和 数据总线	分时复用数据和 地址总线
数据总线 宽度	越宽越快 (例如: 64位)	越窄越便宜 (例如: 8位)
传输块大小	块越大总线开销越小	每次传送单字
总线主设备	多个(需要仲裁)	单个(无需仲裁)
分离事务	采用	不用
定时方式	同步	异步

总线的设计

- □ 分离事务总线
 - 在有多个主设备时,总线通过数据打包来提高总线带宽(将总线事务分为请求和应答),而不必在整个传输过程中都占有总线。



总线的设计

- □ 同步总线
 - ■同步总线上所有设备使用统一的总线系统时钟。
 - 优点:成本低,因为它不需要设备之间互相确定时序的逻辑。
 - 缺点: 总线操作必须以相同的速度运行。
- □ 异步总线
 - 异步总线上的设备之间没有统一的系统时钟,设备自己内部定时。

几种常用的并行总线

	IDE / Ultra ATA	SCSI	PCI	PCI-X
数据宽度	16bit	8 / 16bit	32 / 64bit	32 / 64bit
时钟频率 MHz	100	10 (Fast) 20 (Ultra) 40 (Ultra2) 80 (Ultra3) 160 (Ultra4)	33 / 66	66 / 100 / 133
主设备数量	一个	多个	多个	多个
峰值带宽	200MB/s	320MB/s	533MB/s	1066MB/s
同步方式	异步	异步	同步	同步
标准	无	ANSI X3.131	无	无

并行总线宽度大,适合于速度要求高的场合。

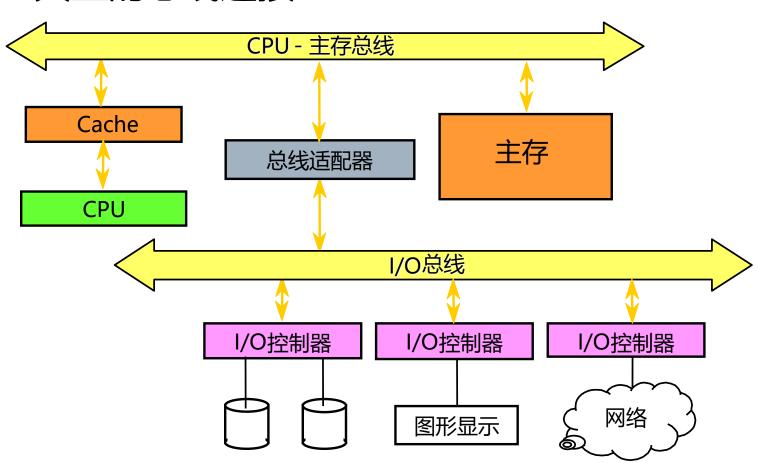
几种常用的串行总线

	I ² C	1-wire	RS-232	SPI
数据竞度 (bit)	1	1	2	1
信号线数量	2	1	9 / 25	3
时钟频率 (MHz)	0.4 ~ 10	异步	0.04或异步	异步
总线主设备数量	多个	多个	多个	多个
峰值带宽 (Mb/s)	0.4 ~ 3.4	0.014	0.192	1
同步方式	异步	异步	异步	异步
标准	无	无	EIA, ITU-T V.21	无

串行总线宽度小,适用于嵌入式系统。如基于RS-232的COM1 COM2接口。

设备的连接

□ 典型的总线连接



设备的连接

- □ CPU寻址I/O设备的方式
 - 存储器映射I/O或统一编址
 - I/O设备单独编址
 - 无论选择哪一种编址方法,每个I/O设备都提供 状态寄存器和控制寄存器。
- □ 设备的连接和工作方式
 - 程序查询、中断、DMA、通道处理机

设备的连接

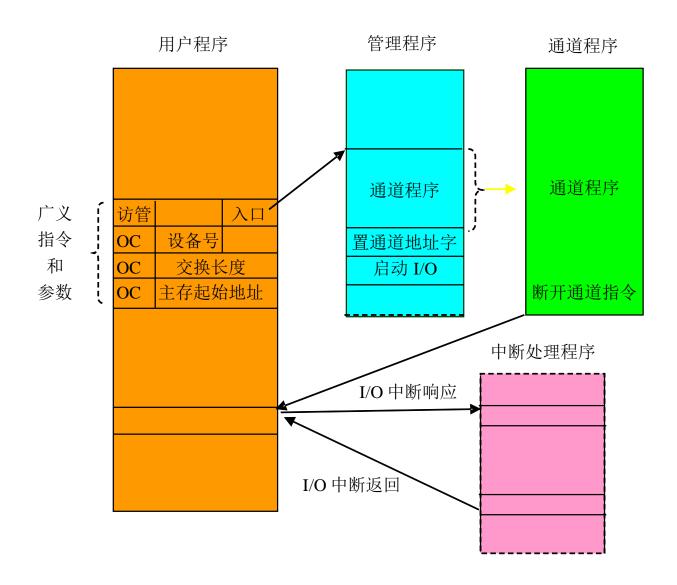
- □ 程序查询、中断和DMA方式管理外围设备会引起两个问题:
 - 所有外围设备的I/O工作都要涉及CPU, CPU的I/O 负担很重,不能专心于用户程序的计算。
 - 大型计算机系统中的外围设备台数众多,CPU管理的开销巨大。
- □ 解决上述问题的方法:
 - 采用通道处理机

- □ 通道处理机能够负担外围设备的大部分I/O工作。
- □ 通道处理机:能够执行有限I/O指令,并且能够被多台外围设备共享的**小型DMA专用处理机**。
- □ 通道的功能:
 - ① 接受CPU发来的I/O指令,从而指定外围设备与通 道相连接;
 - ② 执行通道程序,从主存中取出通道指令,对通道指令, 令进行译码,向被选中的设备控制器发出操作命令;
 - ③ 给出外围设备的有关地址,即进行读/写操作的数据所在的位置。如磁盘存储器的柱面号、磁头号、扇区号等;

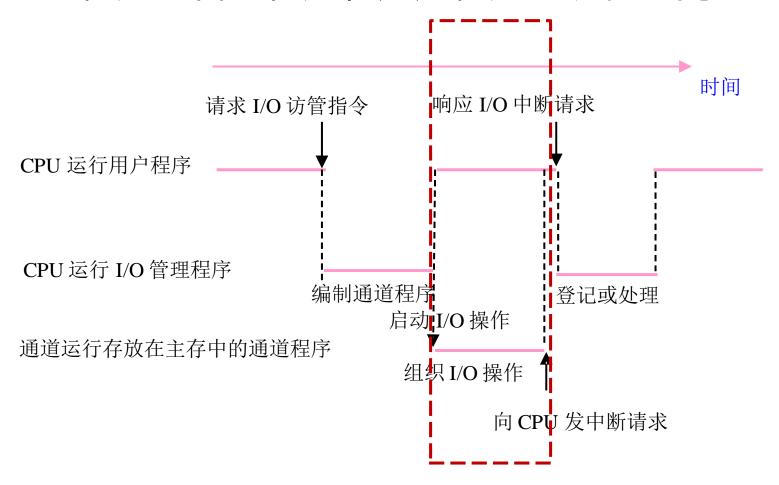
□ 通道的功能:

- ④ 给出主存缓冲区的首地址,存放从外围设备上输入 /将要输出到外围设备中去的数据。
- ⑤ 控制外围设备与主存缓冲区之间数据交换的个数,并进行计数,并判断数据传送工作是否结束。
- ⑥ 指定传送工作结束时要进行的操作。
- ⑦ 检查外围设备的工作状态,是正常或故障。根据需要将设备的状态信息送往主存指定单元保存。
- ⑧ 在数据传输过程中完成必要的格式变换。例如:把 字拆卸为字节,或者把字节装配成字。

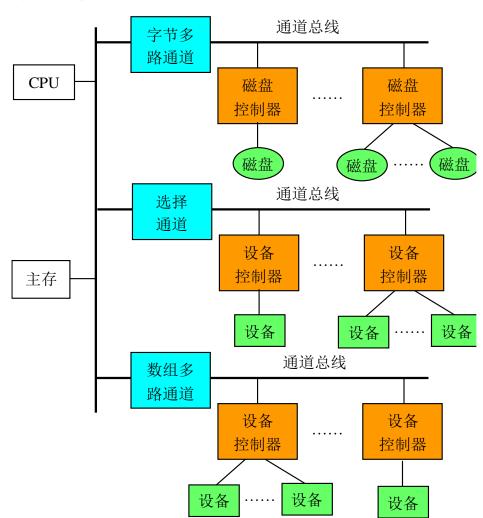
- □ 通道对外围设备的控制通过I/O接口和设备控制器进行,工作过程如下:
 - 1. 在用户程序中使用**访管指令**进入管理程序,由CPU 通过管理程序组织一个**通道程序**,并启动通道。
 - 2. 通道处理机执行CPU为它组织的通道程序,完成指 定的数据I/O工作。
 - 通道处理机执行通道程序是与CPU执行用户程序并行的。
 - 3. 通道程序结束后向CPU发**中断请求**。CPU响应这个中断请求后,第二次进入操作系统,调用管理程序对I/O中断请求进行处理。



□ 通道程序、管理程序和用户程序的执行时间



- □ 通道种类,通常分为3类:
 - ■字节多路通道
 - 选择通道
 - ■数组多路通道



- □ 字节多路通道
 - 为多台**低速或中速**的外围设备服务;
 - 采用分时方式工作,依靠它与CPU之间的高速数据 通路分时为多台设备服务。
- □ 选择通道
 - 为多台高速外围设备服务;
 - 传送数据期间,通道**只能为一台高速外围设备服务**, 在不同时间内可以选择不同设备。

- □ 数组多路通道
 - 数组多路通道适于为**高速**设备服务;
 - 每次选择一个高速设备后**传送一个数据块**,并 轮流为多台外围设备服务;
 - 数组多路通道之所以能够并行地为多个高速外 围设备服务,是因为这些高速外围设备并不能 在整个数据输入输出时间内单独利用通道的全 部传输能力。

- □ 通道中的数据传送过程
 - ■字节多路通道的数据传送过程
 - 通道每连接一个外围设备,只传送一个字节,然后又与另一一台设备连接,并传送一个字节。
 - 数组多路通道的数据传送过程
 - □ 每连接一台高速设备,传送一个数据块,传送完成后,又与另一台高速设备连接,再传送一个数据块。
 - ■选择通道的工作过程
 - □ 每连接一个外围设备,就把这个设备的n个字节全部传送 完成,然后再与另一台设备相连接。

- □ 通道中数据的传送过程与流量分析
 - 通道流量:一个通道在数据传送期间,单位时间内能够传送的最大数据量,一般用**字节个数**来表示。 又称为通道吞吐率,通道数据传输率等。
 - 通道最大流量:一个通道在满负荷工作状态下的流量。

- □ 流量计算公式
 - T_S: 设备选择时间。
 - T_D: 传送一个字节所用的时间。
 - p: 在一个通道上连接的设备台数,且**这些设备同时都 在工作**。
 - n: 每台设备传送的字节数,这里为了方便分析假设每台设备传送的字节数都相同。
 - k: 数组多路通道传输的一个数据块中的包含的字节数。 在一般情况下, k<n。对于磁盘、磁带等磁表面存储器, 通常k=512。
 - T: 通道完成全部数据传送工作所需时间。

- □ 传输时间计算公式:
 - 字节多路通道:

$$T_{BYTE} = (T_S + T_D) \times p \times n$$

■ 选择通道:

$$T_{\text{SELECT}} = (\frac{T_{\text{S}}}{n} + T_{\text{D}}) \times p \times n$$

■ 数组多路通道:

$$T_{BLOCK} = (\frac{T_S}{k} + T_D) \times p \times n$$

- □ 最大流量
 - 字节多路通道

$$f_{\text{MAX-BYTE}} = \frac{pn}{(T_{\text{S}} + T_{\text{D}})pn} = \frac{1}{T_{\text{S}} + T_{\text{D}}}$$

选择通道

$$f_{\text{MAX-SELECT}} = \frac{pn}{(\frac{T_{\text{S}}}{n} + T_{\text{D}})pn} = \frac{1}{\frac{T_{\text{S}}}{n} + T_{\text{D}}}$$

数组多路通道
$$f_{MAX-BLOCK} = \frac{pn}{(\frac{T_S}{k} + T_D)pn} = \frac{1}{\frac{T_S}{k} + T_D}$$

- □ 实际流量小于最大流量

P 字节多路通道
$$f_{BYTE} \leq f_{MAX-BYTE}$$

选择通道

$$f_{\text{SELECT}} \leq f_{\text{MAX-SELECT}}$$

$$lacksymbol{\mathsf{BLOCK}}$$
 数组多路通道 $\mathbf{f}_{\mathrm{BLOCK}} \leq \mathbf{f}_{\mathrm{MAX-BLOCK}}$

Next Topic Interconnection Network